Отчет по лабораторной работе №4.

Бизнес логика варианта 8:

Сформировать результирующий вектор как среднее по каждой строке исходной квадратной матрицы.

В данной работе рассматривается вариант распараллеливания с использованием технологии CUDA.

Данные генерятся Python скриптом и передаются исполняющей программе по TCP. Результирующий вектор возвращается по сетевому протоколу процессу генератора. В нём проверяется правильность полученного результата, затем данные о времени исполнения выводятся в консоль. Скрипт принимает три параметра: размер генерируемых данных в мегабайтах, порт для отправки данных и порт для получения результирующего вектора со временем исполнения. Сам скрипт приведен ниже.

```
import sys, os, math, socket
import numpy as np
Random matrix stream generator for
Hybrid computing labs
Usage:
<script_name>.py [stream_size_in_MegaBytes] [tcp_port_out] [tcp_port_in]
Produces stream with square matrix of floats
and sends it as byte stream to tcp port out
and returns result received from tcp port in
NUM AVERAGES DISPLAYED = 3
def send_file_to_socket(port, file_path):
   Sends string as byte stream to an open tcp socket
   sock = socket.socket(socket.AF INET, socket.SOCK STREAM)
   server_address = ('localhost', int(port))
   sock.connect(server_address)
   with open(file path, 'rb') as input file:
        sock.sendfile(input_file)
   sock.close()
   os.remove(file path)
```

```
def get_string_from_socket(port, check_vector):
   Listens to tcp port until get
   all the stream and then prints it
   sock = socket.socket(socket.AF_INET, socket.SOCK_STREAM)
   server address = ('localhost', int(port))
   sock.bind(server_address)
   sock.listen(1)
   connection, _ = sock.accept()
   result = []
   data = connection.recv(256)
   while data:
       result.append(data)
       data = connection.recv(256)
   result_str = ''.join([part.decode() for part in result])
   lines = result_str.split('\n')
   execution_time = lines[-2]
   numbers = lines[0].split(' ')
   assert len(numbers)-1 == len(check_vector)
   for i in range(len(check_vector)):
       assert math.fabs(float(numbers[i]) - check_vector[i]) < 0.0000001</pre>
   print(len(numbers)-1)
   print(' '.join(numbers[:NUM_AVERAGES_DISPLAYED]))
   print(execution time)
   connection.close()
   sock.close()
def generate_stream_with_matrix(sizePorts):
   Function to generate file with
   random matrix of given size
   sizeInBytes = float(sizePorts[0]) * (2**20) # 1 Mb = 2^20 bytes
   num_rows_and_cols = int(math.sqrt(sizeInBytes / 11)) # 11 byte chars for each
 number
   matrix = np.random.rand(num rows and cols, num rows and cols)
   print(len(matrix))
   avg_vector = [round(sum(vector) / len(vector), 8) for vector in matrix]
   print(' '.join([str(avg) for avg in avg_vector[:NUM_AVERAGES_DISPLAYED]]))
   matrix_file_path = str(num_rows_and_cols) + '.mtrx'
   np.savetxt(matrix_file_path, matrix, fmt='%.8f', delimiter=' ')
   # matrix_str = np.array2string(matrix, formatter={'float_kind':lambda x: "%.8
```

```
# print(matrix_str.split('\n')[0])
send_file_to_socket(sizePorts[1], matrix_file_path)
get_string_from_socket(sizePorts[2], avg_vector)

if __name__ == "__main__":
    if len(sys.argv) > 2:
        generate_stream_with_matrix(sys.argv[1:])
    else:
        print("Usage: <script_name>.py [stream_size_in_MegaBytes] [tcp_port_out]
[tcp_port_in]")
```

Описание алгоритма выполнения бизнес-логики:

Программа включает вспомогательные функции:

- 1) double getMilliseconds() получает текущее машинное время в миллисекундах.
- 2) int* listen_to_port(int port) открывает соединение для переданного порта и возвращает дескрипторы соединения и сокета.
- 3) void close_connection(int connection, int sfd) закрывает соединение и сокет.
- 4) void send_stream_to_port(int port, char* stream) отправляет массив символов на соединение, открытое по указанному порту.
- 5) void convertVectorToFlatArray(std::vector<std::vector<float>> matrix, float *flat) конвертирует вектор C++ в плоский массив, внутри по сути выполняется операция обратная получению индекса на GPU.

Верхнеуровневая бизнес-логика происходит в функции int process_stream(int input_port, int output_port, int devId), которая принимает в качестве параметров номера портов для получения данных и передачи результата, а также идентификатор устройства для дальнейшего получения сведений о нём. В этой функции открывается соединение для получения данных, засекается время исполнения, производится копирование из памяти хоста в память устройства и обратно, проводится вычисление результирующего вектора в ядре GPU, который затем вместе со временем выполнения в виде строки отправляется по TCP на порт вывода результата.

Логика получения по сети матрицы воплощена в функции int get_stream_matrix(int connection, std::vector<std::vector<float>> &matrix). В ней передаваемая матрица считывается и записывается в двумерный массив.

В точке входа воплощена следующая логика: в качестве аргументов программа принимает порт для получения данных и порт для передачи результата. Кроме того, вызывается функция CUDA API для получения

идентификатора устройства с использованием аргументов командной стоки. Далее в бесконечной петле запускается функция process_stream, которая ждет данные для обработки и отправляет результат обратно.

Логика распараллеливания воплощена в функции-ядре __global__ void get_avg_vector(float *matrix, float *result, int n), она заключается в следующем: мы получаем индекс треда в рамках текущего грида, если он меньше квадрата размера матрицы, то совершаются атомарные операции суммирования элементов одномерного массива с шагом, который вычисляется по размеру грида blockDim.x * gridDim.x, ячейка результирующего вектора вычисляется путём деления глобального индекса треда на размер матрицы, прибавляемое значение матрицы тоже делится на размер матрицы, так как вычисляется среднее по строке.

В качестве эксперимента я сравнил время исполнения программы для СРU и программы для GPU, получилось, что программа на GPU в среднем на 99% быстрее. Использовалось пять размеров матриц: 10мб, 50мб, 100мб, 500мб и 1000мб.

Код программы для СРU:

```
#include <stdio.h>
#include <stdlib.h>
#include <unistd.h>
#include <ctype.h>
#include <sys/types.h>
#include <sys/socket.h>
#include <arpa/inet.h>
#include <errno.h>
#include <string.h>
#include <time.h>
#include <vector>
#define MAX SIZE 12
int process stream(int input port, int output port);
int main(int argc, char* argv[])
    if (argc < 3)
       printf("Need input and output streams ports as parameters!\n");
       return -1;
    }
    int input port = atoi(argv[1]);
    int output port = atoi(argv[2]);
    for (;;) // forever and ever
        printf("I am waiting for a Matrix at port %d\n", input port);
       process stream(input port, output port);
   return 0;
}
```

```
double getMilliseconds() {
    return 1000.0 * clock() / CLOCKS PER SEC;
int* listen_to_port(int port)
    int sfd, connection;
   int* opts = new int[1]{ 1 };
    if ((sfd = socket(AF INET, SOCK STREAM, 0)) == 0
        || setsockopt(sfd, SOL SOCKET, SO REUSEADDR | SO REUSEPORT, opts,
sizeof(int)))
        printf("%s\n", strerror(errno));
        exit(EXIT FAILURE);
    }
   struct sockaddr in address;
    int addrlen = sizeof(address);
    address.sin family = AF INET;
    address.sin addr.s addr = INADDR ANY;
    address.sin port = htons(port);
    if (bind(sfd, (struct sockaddr*)&address,
        sizeof(address)) < 0 \mid \mid listen(sfd, 3) < 0
        || (connection = accept(sfd, (struct sockaddr*)&address,
(socklen t*) & addrlen)) < 0)
    {
        printf("%s\n", strerror(errno));
        exit(EXIT_FAILURE);
   return new int[2]{ connection, sfd };
}
void close_connection(int connection, int sfd)
    shutdown (connection, SHUT RDWR);
   close(connection);
   shutdown(sfd, SHUT RDWR);
   close(sfd);
void send stream to port(int port, char* stream)
    int sock = 0;
    if ((sock = socket(AF INET, SOCK STREAM, 0)) < 0)
        printf("%s\n", strerror(errno));
        exit(EXIT_FAILURE);
    }
   struct sockaddr in serv addr;
   serv addr.sin family = AF INET;
    serv addr.sin addr.s addr = INADDR ANY;
   serv_addr.sin_port = htons(port);
   if (connect(sock, (struct sockaddr*)&serv addr, sizeof(serv addr)) <</pre>
0)
```

```
{
        printf("%s\n", strerror(errno));
        exit(EXIT FAILURE);
   send(sock, stream, strlen(stream), 0);
   shutdown(sock, SHUT WR);
   close(sock);
}
float get line avg(std::vector<float> line)
   int count = line.size();
   float sum = 0;
   for (int i = 0; i < count; i++)
        sum += line[i] / count;
   return sum;
}
std::vector<char> get avg vector(std::vector<std::vector<float>> matrix)
   std::vector<float> result;
   int matrix size = matrix.size();
   result.reserve(matrix size);
   for (int i = 0; i < matrix size; i++)</pre>
        double avg = get line avg(matrix[i]);
        result[i] = avq;
   std::vector<char> char result;
   for (int i = 0; i < matrix size; i++)</pre>
        char* avg str = new char[MAX SIZE];
        sprintf(avg_str, "%.8f ", result[i]);
        char result.insert(char result.end(), avg str, avg str +
strlen(avg str));
   }
   char result.push back('\n');
   return char result;
int get stream matrix(int connection, std::vector<std::vector<float>>
&matrix)
   int buffer size = 1;
   char* buffer = new char[buffer size];
   std::vector<char> number;
   std::vector<float> line;
   int stream size = 0;
   while (read(connection, buffer, buffer size) > 0)
```

```
{
        stream size++;
        int num bytes = 1;
        while (buffer[0] != '\n' && num bytes > 0)
            if (buffer[0] == ' ')
            {
                line.push back(atof(&number[0]));
                number.clear();
            }
            else
                number.push back(buffer[0]);
            num bytes = read(connection, buffer, buffer size);
            stream size++;
        line.push back(atof(&number[0]));
        number.clear();
        matrix.push_back(line);
        line.clear();
    }
   return stream size;
}
int process_stream(int input_port, int output_port)
    int* connection = listen_to_port(input_port);
    std::vector<std::vector<float>> matrix;
   int stream size = get stream matrix(connection[0], matrix);
   close connection(connection[0], connection[1]);
   double start = getMilliseconds();
    std::vector<char> result = get_avg vector(matrix);
    double end = getMilliseconds();
    double execution time in seconds = (double) (end - start);
   char* buffer = new char[256];
    sprintf(buffer, "%d bytes in %.9f milliseconds\n", stream size,
execution_time_in seconds);
    result.insert(result.end(), buffer, buffer + strlen(buffer));
   result.push back('\0');
   send_stream_to_port(output_port, &result[0]);
   return 0;
}
```

Код программы для GPU:

```
#include <stdio.h>
#include <stdlib.h>
#include <unistd.h>
#include <ctype.h>
#include <sys/types.h>
#include <sys/socket.h>
#include <arpa/inet.h>
#include <errno.h>
#include <string.h>
#include <vector>
#include <time.h>
// CUDA runtime
#include <cuda runtime.h>
// helper functions and utilities to work with CUDA
#include <helper functions.h>
#include <helper_cuda.h>
#define MAX SIZE 12
int process stream(int input port, int output port, int devId);
int main(int argc, char* argv[])
    if (argc < 3)
       printf("Need input and output streams ports as parameters!\n");
       return -1;
    }
    int input port = atoi(argv[1]);
    int output port = atoi(argv[2]);
    int devId = findCudaDevice(argc, (const char **)argv);
    for (;;) // forever and ever
        printf("I am waiting for a Matrix at port %d\n", input port);
        process stream(input port, output port, devId);
   return 0;
}
double getMilliseconds() {
   return 1000.0 * clock() / CLOCKS PER SEC;
int* listen to port(int port)
    int sfd, connection;
   int* opts = new int[1] { 1 };
    if ((sfd = socket(AF INET, SOCK STREAM, 0)) == 0
        || setsockopt(sfd, SOL SOCKET, SO REUSEADDR | SO REUSEPORT, opts,
sizeof(int)))
    {
```

```
printf("%s\n", strerror(errno));
        exit(EXIT FAILURE);
    }
   struct sockaddr in address;
    int addrlen = sizeof(address);
    address.sin_family = AF_INET;
    address.sin_addr.s_addr = INADDR_ANY;
   address.sin port = htons(port);
    if (bind(sfd, (struct sockaddr*) &address,
        sizeof(address)) < 0 | | listen(sfd, 3) < 0
        || (connection = accept(sfd, (struct sockaddr*)&address,
(socklen t*) & addrlen)) < 0)
    {
        printf("%s\n", strerror(errno));
        exit(EXIT FAILURE);
   return new int[2]{ connection, sfd };
void close connection (int connection, int sfd)
   shutdown (connection, SHUT RDWR);
   close(connection);
   shutdown(sfd, SHUT RDWR);
   close(sfd);
void send stream to port(int port, char* stream)
    int sock = 0;
    if ((sock = socket(AF INET, SOCK STREAM, 0)) < 0)
        printf("%s\n", strerror(errno));
        exit(EXIT FAILURE);
    }
   struct sockaddr in serv addr;
    serv addr.sin family = AF INET;
    serv_addr.sin_addr.s_addr = INADDR_ANY;
   serv addr.sin port = htons(port);
   if (connect(sock, (struct sockaddr*)&serv addr, sizeof(serv addr)) <</pre>
0)
    {
        printf("%s\n", strerror(errno));
        exit(EXIT FAILURE);
   send(sock, stream, strlen(stream), 0);
   shutdown (sock, SHUT WR);
   close(sock);
}
int get stream matrix(int connection, std::vector<std::vector<float>>
&matrix)
{
    int buffer size = 1;
```

```
char* buffer = new char[buffer size];
   std::vector<char> number;
    std::vector<float> line;
    int stream size = 0;
   while (read(connection, buffer, buffer size) > 0)
        stream_size++;
        int num bytes = 1;
        while (buffer[0] != '\n' && num bytes > 0)
            if (buffer[0] == ' ')
                line.push back(atof(&number[0]));
                number.clear();
            else
                number.push back(buffer[0]);
            num_bytes = read(connection, buffer, buffer_size);
            stream size++;
        line.push back(atof(&number[0]));
        number.clear();
        matrix.push back(line);
        line.clear();
    }
   return stream size;
void convertVectorToFlatArray(std::vector<std::vector<float>> matrix,
float *flat)
    int msize = matrix.size();
    for (int i = 0; i < msize; i++)
        for (int j = 0; j < msize; j++)
            flat[j + (i * msize)] = matrix[i][j];
        }
    }
 }
 global void get avg vector(float *matrix, float *result, int n)
    int row idx = blockIdx.x * blockDim.x + threadIdx.x;
    int nsqrd = n*n;
    if (row idx < nsqrd)
        for (int i = row idx; i < nsqrd; i += blockDim.x * gridDim.x)
            atomicAdd(&result[i / n], matrix[i] / n);
    }
}
int process stream(int input port, int output port, int devId)
```

```
{
    int* connection = listen to port(input port);
    std::vector<std::vector<float>> matrix;
    int stream size = get stream matrix(connection[0], matrix);
    close connection(connection[0], connection[1]);
    int matrix size = matrix.size();
    int row size = matrix size * sizeof(float);
    int flat size = matrix size * matrix size * sizeof(float);
    float *a matrix = (float*)malloc(flat size);
    convertVectorToFlatArray(matrix, a matrix);
    float *d matrix;
    float *d result;
    cudaMalloc(&d matrix, flat size);
    cudaMemcpy(d_matrix, a_matrix, flat_size, cudaMemcpyHostToDevice);
    cudaMalloc(&d result, row size);
    cudaMemset(d result, 0, row size);
    int numSMs;
    cudaDeviceGetAttribute(&numSMs, cudaDevAttrMultiProcessorCount,
devId);
    cudaDeviceProp props;
    cudaGetDeviceProperties(&props, devId);
    printf("Executed on device \"%s\"\n", props.name);
    double start = getMilliseconds();
    get avg vector<<<numSMs, 256>>>(d matrix, d result, matrix size);
    double end = getMilliseconds();
    double execution time in seconds = (double) (end - start);
    float *float result = (float*)malloc(row size);
    cudaMemcpy(float result, d result, row size, cudaMemcpyDeviceToHost);
    std::vector<char> result;
    for (int i = 0; i < matrix size; i++)
        char* avg str = new char[MAX SIZE];
        sprintf(avg str, "%.8f ", float result[i]);
        result.insert(result.end(), avg str, avg str + strlen(avg str));
    }
    result.push back('\n');
    char* buffer = new char[256];
    sprintf(buffer, "%d bytes in %.9f milliseconds\n", stream size,
execution time in seconds);
    result.insert(result.end(), buffer, buffer + strlen(buffer));
    result.push back('\0');
    send stream to port(output port, &result[0]);
```

```
cudaFree(d_result);
cudaFree(d_matrix);
free(float_result);
free(a_matrix);

return 0;
}
```

Makefile и прочие вспомогательные файлы можно увидеть в публичном репозитории:

https://github.com/RinSer/MephiHybridComputing/tree/master/Lab1/Lab4

График зависимости времени выполнения от размера данных (по горизонтали отложены байты, по вертикали – время исполнения в миллисекундах), синий график – CPU, красный – GPU:

